牧场池塘与圆形水槽检测报告

目标：从卫星/航空影像中自动找出放牧牧场内所有可供牛饮水的水源——天然或土坝池塘（stock pond），以及人工放置的圆形水槽和储水罐——作为长期跟踪"水里还有没有水"的第一步。最终模型基于自监督预训练的 ViT-L（DINOv3-sat），并在本县未标注影像上做了领域自监督训练（第 7 节）。

7,707
全县池塘足迹（自监督集成模型，NAIP 2018/2020/2022 三期并集）

6,735 → 3,072
有水池塘数，2018 年秋 → 2022 年夏（严重干旱）

F1 0.845 · IoU 0.905
池塘检测（测试区，原模型 0.833 · 0.829）；NWI 有水池塘召回 81%

3,026
全县圆形水槽/储水罐（原模型 1,849）；测试区召回 78%，精度 60–87%

数据：USDA NAIP、USFWS NWI、Census TIGER、Microsoft Building Footprints、TWDB 井位数据库、Google 卫星图（仅水槽检测）、Esri World Imagery（目视核验）。
分析时间：2026 年 10 月 19–22 日 · 代码与数据：服务器 `/home/ychen289/whe/pond`

1. 摘要

- **两类水源，两套模型。**池塘用公开的 NAIP 航空影像（0.6 m，含近红外）做语义分割；圆形水槽直径多为 2–12 m，在 NAIP 上只有几个像素，改用 Google 卫星图（约 0.25 m）做目标检测，再用约 0.13 m 的切片做类型复核。
- **池塘检测可用。**在不参与训练的测试区（约 650 km^2），人工核验 60 个随机检出，精度 88%（严格）–93%（宽松）；核验 60 个 NWI 登记池塘，其中 42 个当年有水，模型检出 34 个，召回 81%。误检主要是柏油路和深色屋顶；漏检主要是树荫下的小水面和满池绿藻的池塘。
- **可以做逐年水情跟踪。**同一模型用于 2018、2020、2022 三期影像（2018/2020 先做辐射匹配）。全县有水池塘从 6,688 个降到 3,152 个；小于 500 m^2 的池塘在 2022 年只有 17% 还有水，1 公顷以上的仍有 82%。
- **圆形水槽检测初步可用。**两阶段系统在测试区召回 72%，精度 67%–85%，全县共 1,849 个。关键难点是：高分辨率下圆形草捆和草捆喂料架与水槽外观几乎一样，单靠检测器的高置信检出中只有 29% 是储水设施；增加第二阶段分类后精度大幅提升。
- **自监督升级（第 7 节）。**换成自监督预训练的 ViT-L（DINOv3-sat，并在本县未标注影像上继续自监督训练、学会使用近红外）后：池塘集成模型像素 IoU 0.829 → 0.905、F1 0.833 → 0.845；水槽改用 ViT 稠密检测 + ViT 分类，同等召回下找到的真实设施约多 30%，召回可提高到 78–89%；标注少时自监督优势最大：水槽分类约 90 个标注时 F1 0.61 → 0.76；池塘只用 10% 训练影像时，本县领域自监督模型（F1 0.831）即追平全量数据的 U-Net（0.833）。
- **主要限制。**评估样本量不大（±约 12 个百分点）；Google 底图日期未知且有使用条款限制，只适合定位水槽，不适合判断某一天是否有水。

2. 研究区与数据来源

研究区为德克萨斯州中部 Hamilton County（约 2,170 km^2），以放牧牧场为主，散布大量土坝池塘（当地俗称 stock tank）、风车/水井旁的圆形水槽和金属储水罐。没有现成的人工标注，所有训练标签都由公开数据自动生成或由本人人工标注。

数据	来源 / 获取方式	分辨率 · 时间	用途
NAIP 航空正射影像	USDA；Microsoft Planetary Computer STAC 接口下载（77 个四分幅 × 3 年，约 100 GB）	0.6 m，RGB+近红外；2018 年 10–11 月、2020 年 8–12 月、2022 年 7 月	池塘检测主数据、逐年水情
National Wetlands Inventory (NWI)	USFWS 湿地地图服务（ArcGIS REST 接口）	矢量；全县 5,497 个 "Freshwater Pond"	池塘位置先验（弱标签）；召回核验
TIGER 道路	U.S. Census Bureau，2023	矢量	困难负样本（柏油路像水）
Microsoft Building Footprints	Planetary Computer（ms-buildings）	矢量；县内 12,222 栋	困难负样本、泳池标记
TWDB 水井数据库（SDR + GWDB）	Texas Water Development Board 公开下载	点位；用途为 "Stock" 的 292 口	寻找圆形水槽的线索（仅使用坐标与用途）
Google 卫星图瓦片	Google Maps XYZ 瓦片（按需求方允许使用）；z19 全县 52 万张，z20 按需	z19 ≈0.25 m，z20 ≈0.13 m；拍摄日期未公开	圆形水槽检测与类型分类
Esri World Imagery	ArcGIS 在线底图（WorldView-2，2021-12）	约 0.5 m	人工目视核验的第二视角

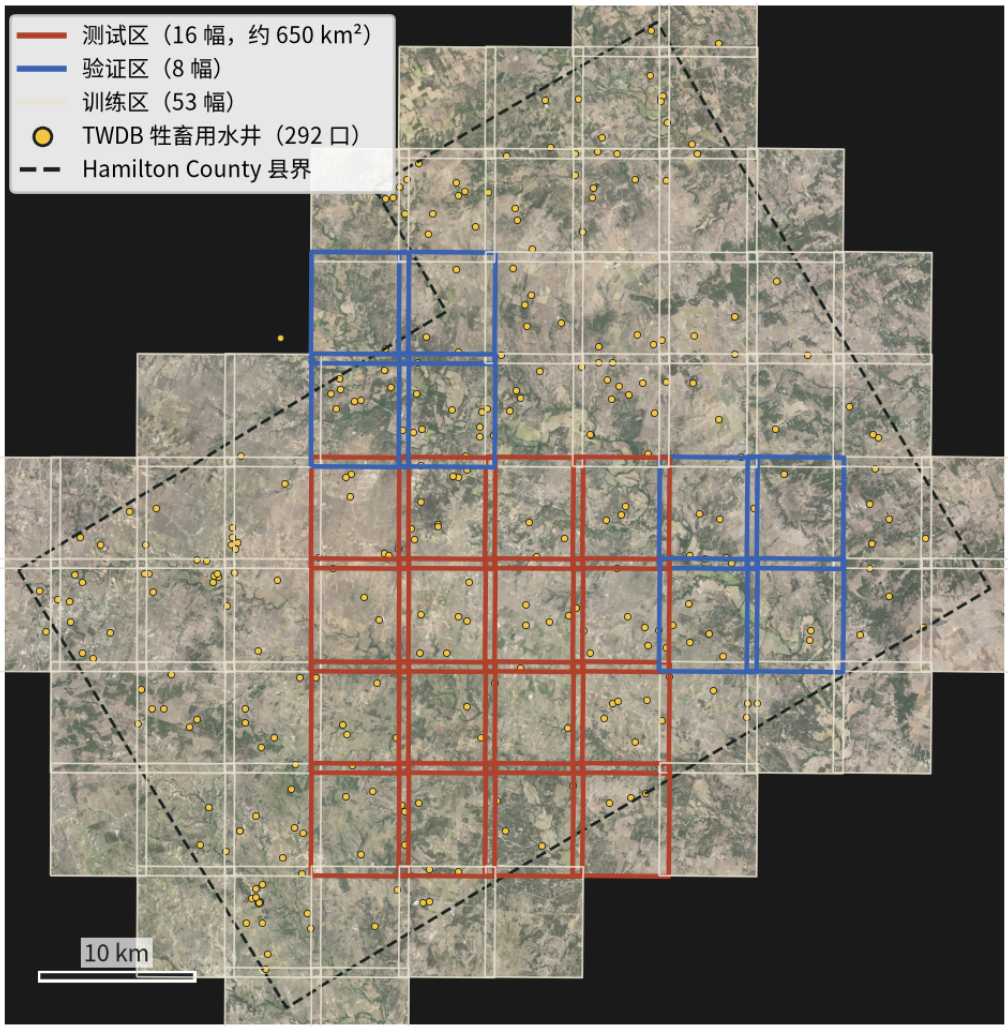


图 1 研究区与数据划分。底图为 NAIP 2022 县域缩略图；方框为 NAIP 四分幅。训练/验证/测试按空间整块划分，测试区（红）是县中南部 16 幅连续影像，任何模型都不使用其中的数据训练。黄点为 TWDB 登记的牲畜用水井。

3. 方法

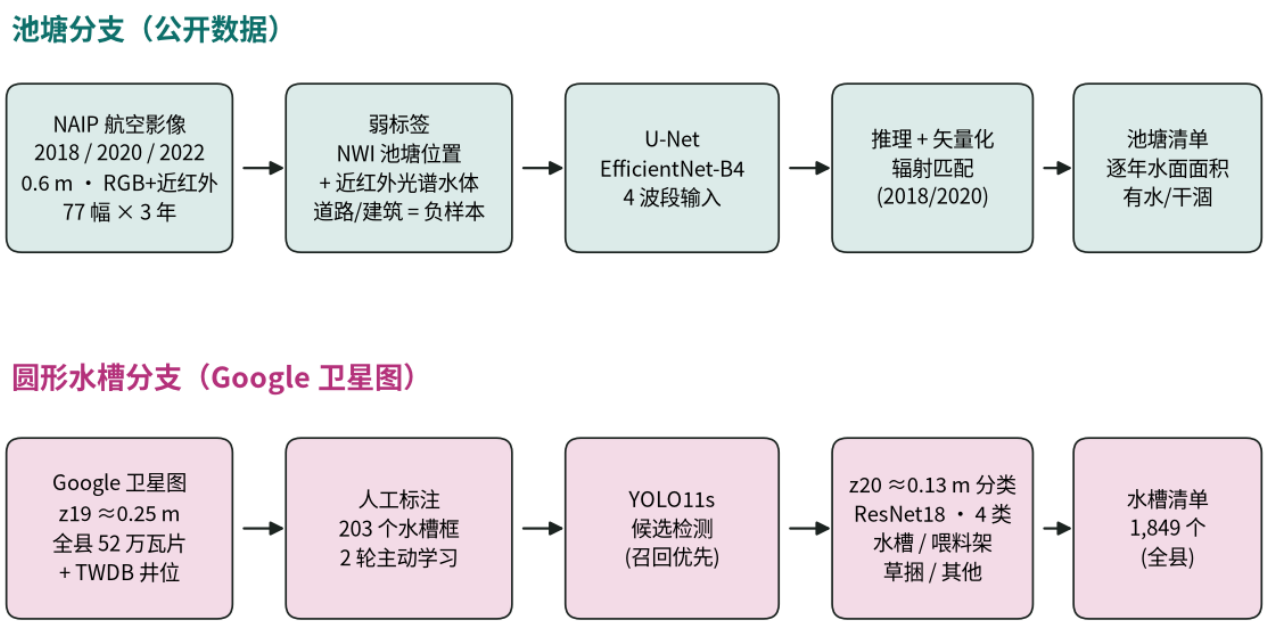


图 2 技术流程。上：池塘分支，完全基于公开数据；下：圆形水槽分支，候选检测在 z19 影像上进行，类型复核在更清晰的 z20 影像上进行。

3.1 池塘：弱标签 + 语义分割

弱标签。NWI 池塘多边形常有 20–50 m 偏移，且很多早已干涸，不能直接作为标签。做法是：用近红外特征 NIR < 0.8×R 且 NIR < 0.8×G 提取光谱水体，再按连通域分类——位于 NWI 池塘 60 m 缓冲区内、或形状紧凑且 NDWI > 0.25 的水体为正样本；落在道路/建筑上、狭长（沟渠）、或低 NDWI 的深色翻耕地为负样本；无法确定的设为"忽略"（不参与损失计算）。绿藻覆盖的池塘不满足光谱规则，因此 NWI 池塘内部的非水像素也设为忽略，避免教模型漏检。

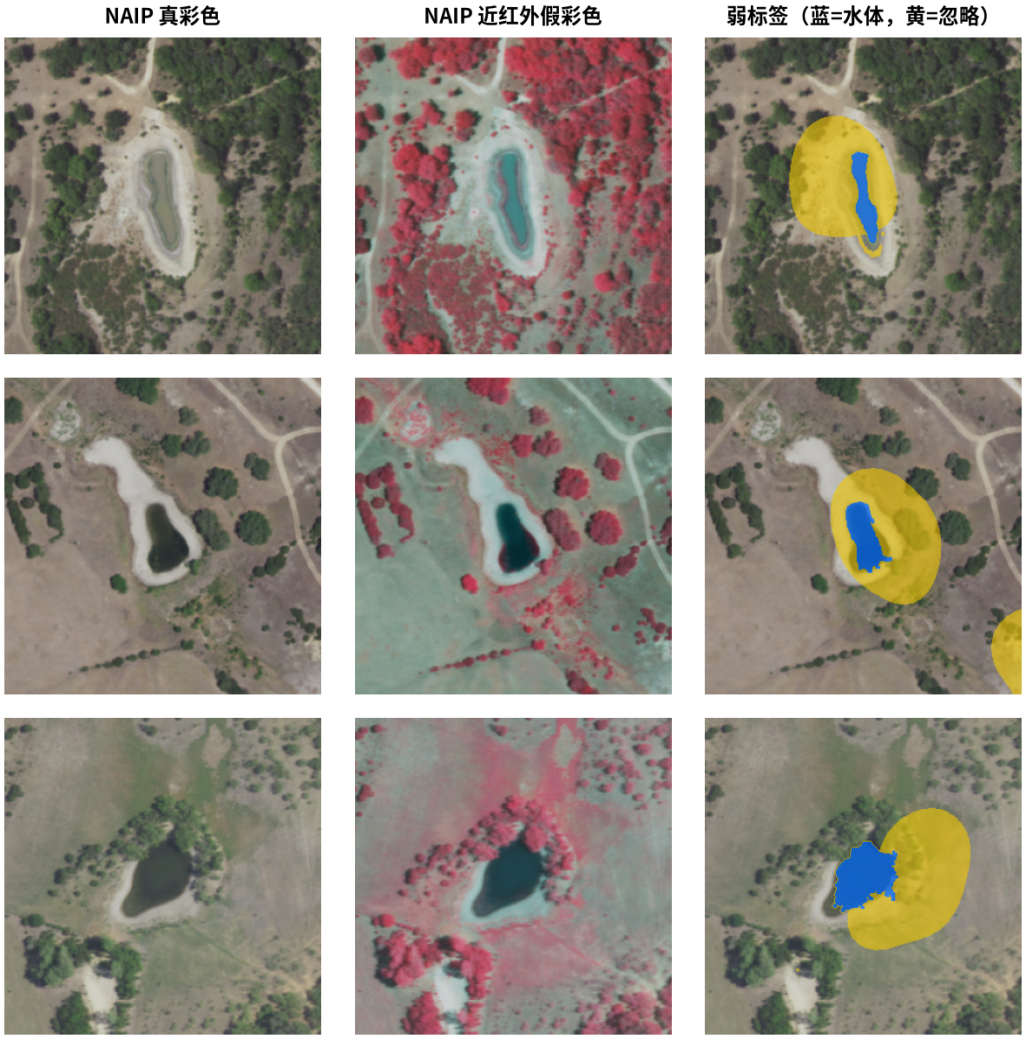


图 3 弱标签示例。左：NAIP 真彩色；中：近红外假彩色（水体呈深蓝/青色，植被呈红色）；右：自动生成的标签，蓝色为水体正样本，黄色为忽略区域。

模型与训练。U-Net（EfficientNet-B4 编码器，ImageNet 预训练），输入 RGB+近红外 4 波段、512×512 像素切片。采样比例为 45% 以水体为中心、25% 以困难负样本（公路、屋顶、深色农田）为中心、30% 随机；损失为加权 BCE + Dice；AdamW + OneCycle 学习率。第一版（v1）没有显式采样困难负样本，测试区目标级 F1 只有 0.59；第二版（v2）加入后提升到 0.83。

推理与跨年份。1024 像素滑窗、水平翻转测试时增强，阈值 0.5 后提取连通域多边形，计算面积、圆度、是否靠近建筑/道路等属性。2018、2020 年影像拍摄于秋季，整体比 2022 年暗约 25%，直接推理会漏掉大量深色清水，因此推理前把每幅影像的各波段均值/方差匹配到 2022 年的统计量。三期检出的并集构成"池塘足迹"清单，逐年统计每个足迹内的水面面积；水面 ≥ 该池塘三年最大值的 10%（且 ≥ 10 m^2）记为当年有水。

3.2 圆形水槽：两阶段检测

为什么换数据。先在 NAIP 上做了斑点检测 + CNN 打分，全县抽查精度只有 12–33%——水槽在 0.6 m 下只有 3–13 个像素，与灌木分不开。Google z19 影像（约 0.25 m）上水槽直径 10–50 像素，清晰可见。

第一阶段：YOLO11s 候选检测。从 TWDB 牲畜井和 NAIP 亮斑候选附近人工挑出并标注 94 个水槽框；之后做两轮主动学习：在训练区运行模型，人工审核高分和中等分数的检出，补充 109 个正样本和 118 个困难负样本（牛群、灌木、草捆、建筑阴影）。最终数据集 991 张训练图、140 张验证图（384 像素切片，放大到 640 输入），共 203 个水槽框。全县按 384 像素窗口、64 像素重叠滑窗推理，跨窗口做 NMS。

第二阶段：z20 类型分类。z20 放大复核发现，单阶段高置信检出中 46% 是圆草捆、21% 是草捆喂料架。因此在约 0.13 m 的 16 m 视窗切片上训练 ResNet18 四分类器（储水设施 / 草捆喂料架 / 圆草捆 / 其他），人工标注 443 个样本（197 储水、108 草捆、29 喂料架、109 其他），5 折交叉验证总体准确率 84%，储水类精度 0.90、召回 0.85。最终输出条件为：YOLO 置信度 ⩾ 0.2 且储水概率 ⩾ 0.8。



图 4 第二阶段要区分的四类候选（z20，约 16 m 视窗）。自上而下：储水罐/水槽（内部是暗色水面或金属罐体，常有阴影）；草捆喂料架（暗色圆环、浅色草料内部、成片踩踏斑）；圆草捆（均匀浅色圆盘，周围无踩踏）；其他（灌木、牛群、车辆、棚子）。

4. 训练的模型

#	模型 · 任务	结构与输入	训练数据与设置	验证指标	状态
1	**U-Net v2（4 波段）** **池塘水面分割**	**U-Net + EfficientNet-B4（ImageNet 预训练）；NAIP RGB+近红外，512×512**	**53 幅训练影像的 v2 弱标签；由 v1 继续训练 20 epoch × 400 iter，batch 16，BCE+Dice**	**val IoU 0.878**	**最终模型**
2	U-Net v1（4 波段） 池塘水面分割	同上	v1 弱标签，未采样困难负样本；约 15 epoch	val IoU 0.90*	已被 v2 取代
3	U-Net v2（仅 RGB） 池塘水面分割	同上，3 波段输入	同模型 1	val IoU 0.816	备用，未单独评估
4	ResNet18（NAIP） 水槽候选打分	NAIP 4 波段 48×48 切片	192 个井周候选人工审核 + 1,500 个未标注候选	CV AUC 0.89	已弃用（全县精度 12–33%）
5	**YOLO11s v3** **圆形水槽候选检测**	**Google z19 RGB，384 px 切片放大至 640**	**203 个水槽框，训练 991 / 验证 140 张；v1→v2→v3 三轮接续训练，早停**	**val mAP@0.5 ≈ 0.5**	**已被模型 10 取代**
6	**ResNet18** **水槽类型分类**	**Google z20 RGB，128 px → 224；4 类**	**443 个人工标注样本，30 epoch，类别加权交叉熵**	**CV 准确率 0.84 储水 P 0.90 / R 0.85**	**已被模型 11 取代**
自监督升级（第 7 节）					
7	领域自监督 ViT-L（NAIP） 自监督预训练	DINOv3-sat ViT-L/16，输入扩为 RGB+NIR	本县 NAIP 3 年未标注影像；DINO + iBOT + KoLeo + Gram anchoring，6,000 次迭代	无标签	骨干网络
8	领域自监督 ViT-L（Google） 自监督预训练	DINOv3-sat ViT-L/16，RGB	全县 52 万张 Google z19 瓦片，7,000 次迭代	无标签	骨干网络
9	**ViT-L 池塘分割 2×** **池塘水面分割**	**DINOv3-sat ViT-L/16 + 多层特征解码器 + 全分辨率细节分支；RGB+NIR，输入放大 2 倍**	**同模型 1 的弱标签，8,000 步，batch 16**	**val IoU 0.900**	**最终（与模型 1 集成）**
10	**ViT-L 稠密水槽检测器** **水槽候选检测**	**同上结构，Google z19 RGB，输出水槽圆盘概率图**	**230 个 z20 复核储水设施 + 333 个困难负样本，3,000 步**	**val 目标 F1 0.79**	**最终第一阶段**
11	**ViT-L 水槽类型分类器** **水槽/喂料架/草捆/其他**	**DINOv3-sat ViT-L/16 微调，z20 128 px → 224**	**584 个 z20 标注（含稠密检测器的困难误检）**	**CV 储水 F1 0.825**	**最终第二阶段**

*v1 与 v2 的验证集不同：v2 的验证集包含公路、农田、屋顶等困难负样本，所以数值更低，但测试区表现明显更好（见第 5 节）。YOLO 的验证集只有约 30 个实例，mAP 波动较大，实际效果以第 5 节的独立测试为准。

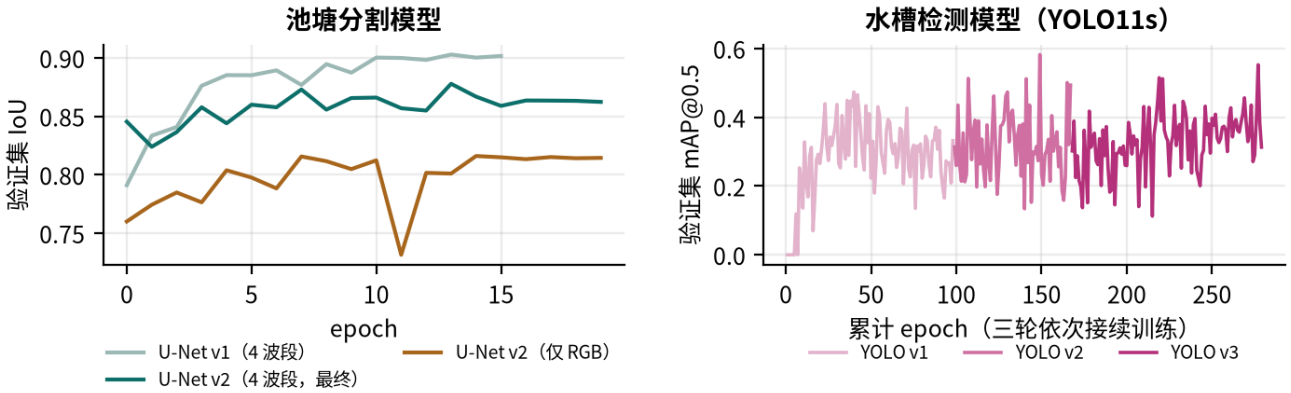


图 5 训练曲线。左：池塘分割模型的验证集 IoU；右：水槽检测模型三轮主动学习接续训练的验证集 mAP@0.5。

权重文件：`runs/unet_rgbn_v2/best.pt`、`runs/unet_rgb_v2/best.pt`、`runs/yolo/tank_v3/weights/best.pt`、`runs/tank_type_cls.pt`。

5. 精度评估

所有评估都在测试区进行，测试区数据从未用于训练或调参。因为弱标签本身不完整，最终结论以人工逐个看图核验为准：每个样本同时查看 NAIP 真彩色、近红外假彩色和 Esri（或 Google z20）高分影像。"严格"把看不清的样本计为错误，"宽松"计为正确。

5.1 池塘

评估方式（测试区，NAIP 2022）	精度	召回	F1
与弱标签对比：纯光谱规则基线	0.12	—	0.21
与弱标签对比：U-Net v1	0.49	0.75	0.59
与弱标签对比：U-Net v2（像素 IoU 0.83）	0.92	0.76	0.83
人工核验：60 个随机检出 / 42 个有水的 NWI 池塘	**0.88–0.93**	**0.81**	**—**

60 个检出中 53 个为真实水体、4 个误检（3 个道路/铁路、1 个深色屋顶）、3 个存疑。60 个随机 NWI 池塘中 18 个（30%）在 2022 年 7 月已经干涸；其余 42 个有水，模型检出 34 个，漏掉的是树荫下很小的水面、满池绿藻或水草覆盖的池塘。

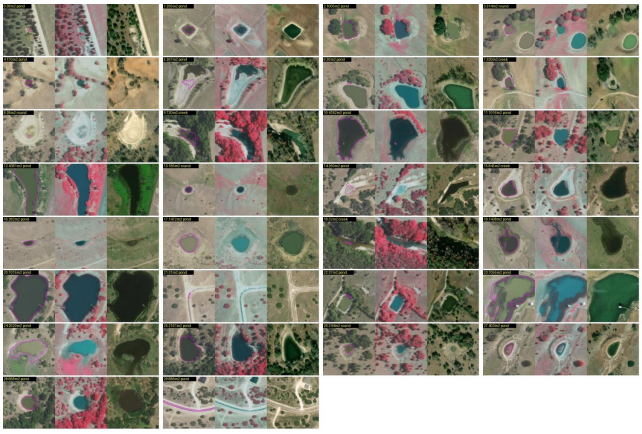


图 6a 精度核验样本（部分）。每组：NAIP 真彩色 + 洋红检测轮廓 | NAIP 近红外 | Esri 2021。

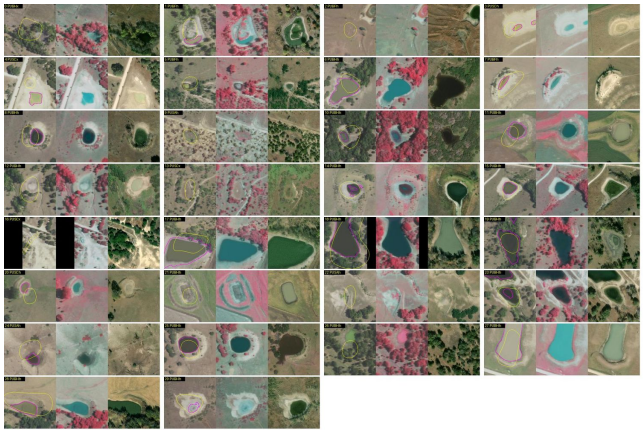


图 6b 召回核验样本（部分）。黄色为 NWI 池塘，洋红为模型检出；无洋红且有水即为漏检。

5.2 圆形水槽

方案（测试区）	召回	精度（严格–宽松）	测试区检出数
NAIP 0.6 m 斑点 + CNN	—	12–33%	—
Google z19 YOLO 单阶段（置信度 ≥ 0.35）	60%	29%	1,025
YOLO + z20 类型分类（最终；置信度 ≥ 0.2、储水概率 ≥ 0.8）	**72%**	**67–85%**	**741**

召回参照集是测试区内独立挑出、并在 z20 下确认的 18 个储水设施，最终系统检出 13 个；精度来自最终检出的随机样本（33 个）在 z20 下逐个核验。剩余误检主要是车辆、拖车、棚子和灌木；漏检主要是被树荫遮挡或位于牲畜棚院内的水槽。

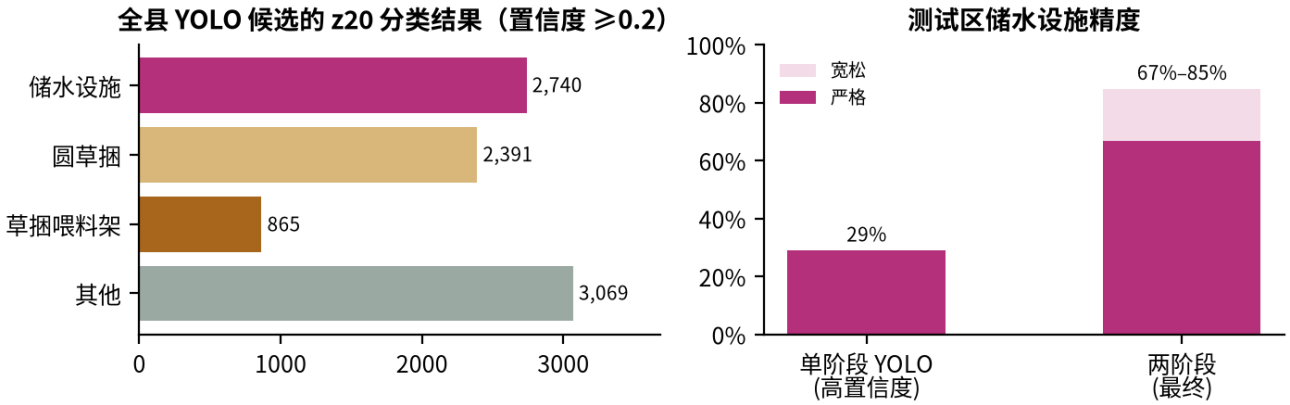


图 7 第二阶段的作用。左：全县 YOLO 候选按 z20 分类的构成，储水设施不到三分之一（最终结果还要求储水概率 ⩾ 0.8，所以是 1,849 个而不是 2,740 个）；右：测试区储水设施精度，单阶段 vs 两阶段。

6. 结果

6.1 全县池塘与三年水情

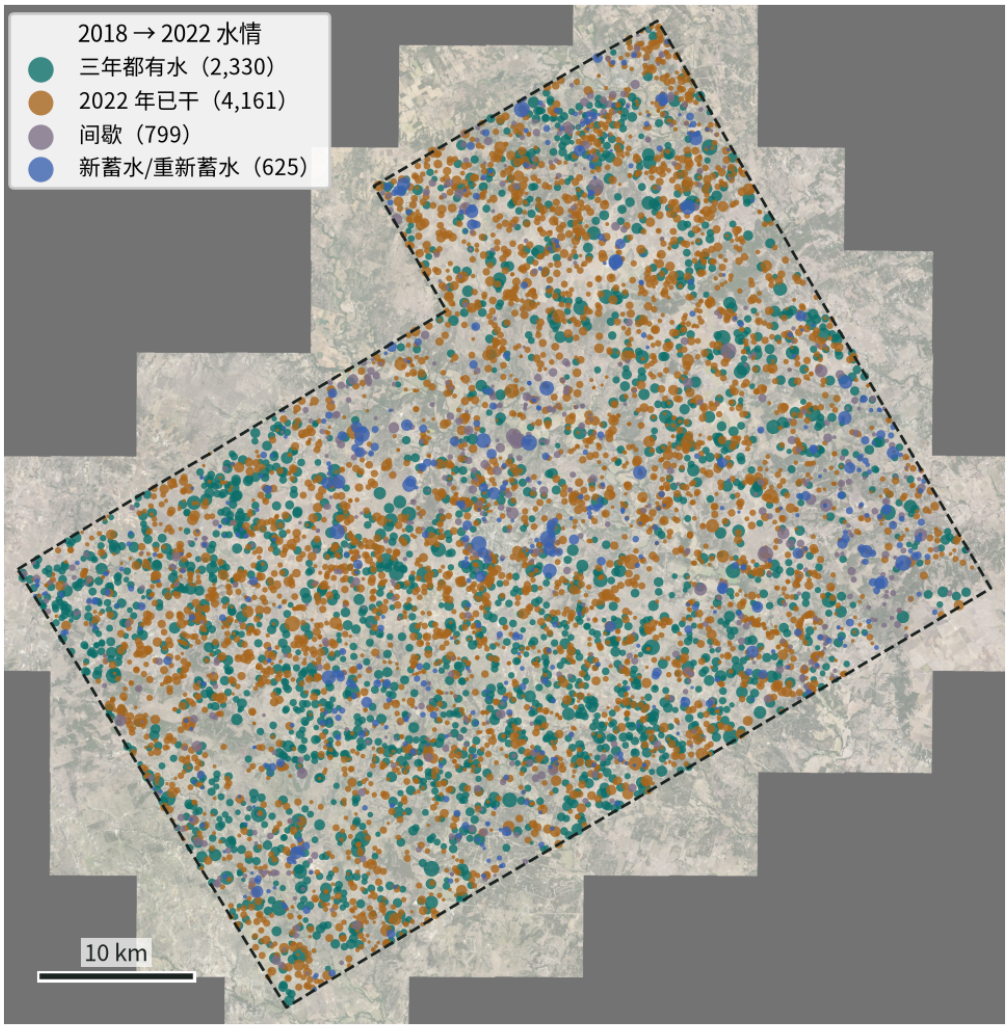


图 8 全县池塘足迹及 2018→2022 水情类别。点大小与池塘面积相关。"2022 年已干"共 4,161 个，大多是小型土池；由于 2022 年召回约 81%，其中混有少量漏检的有水池塘。

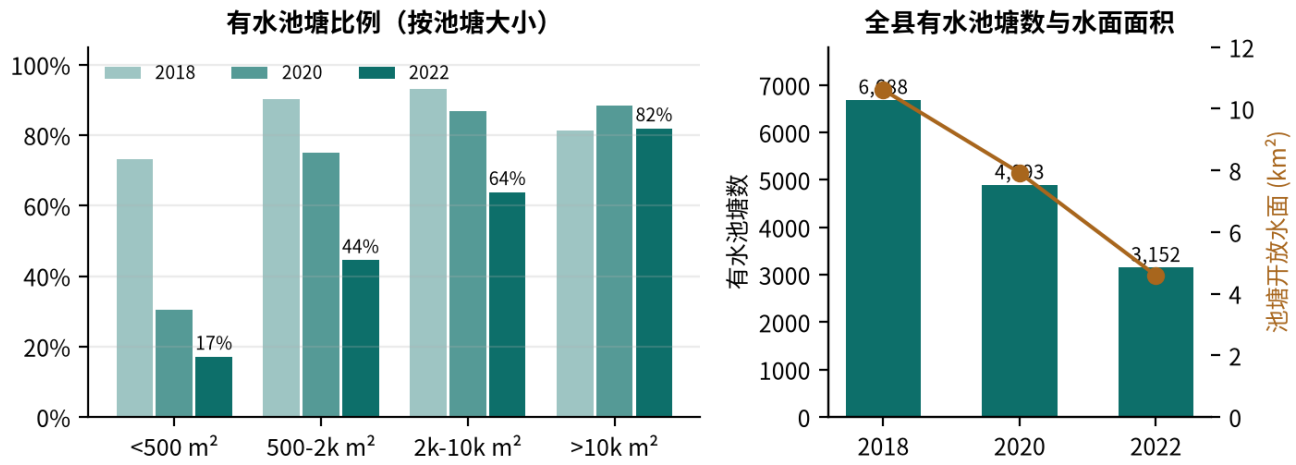


图 9 逐年统计。左：各大小档池塘中有水的比例，小池塘在干旱年最先见底；右：全县有水池塘数（柱）与池塘开放水面总面积（线），10.6 → 7.9 → 4.6 km²。



图 10 跨年份检测示例。随机 24 个"2020 年有水、2022 年未检出"的目标，每组依次为 2020 真彩色 | 2020 近红外 | 2022 真彩色 | 2022 近红外。约 20 个确实是 2020 年有水、2022 年见底的池塘，其余为道路或小阴影斑。

6.2 全县圆形水槽与储水罐

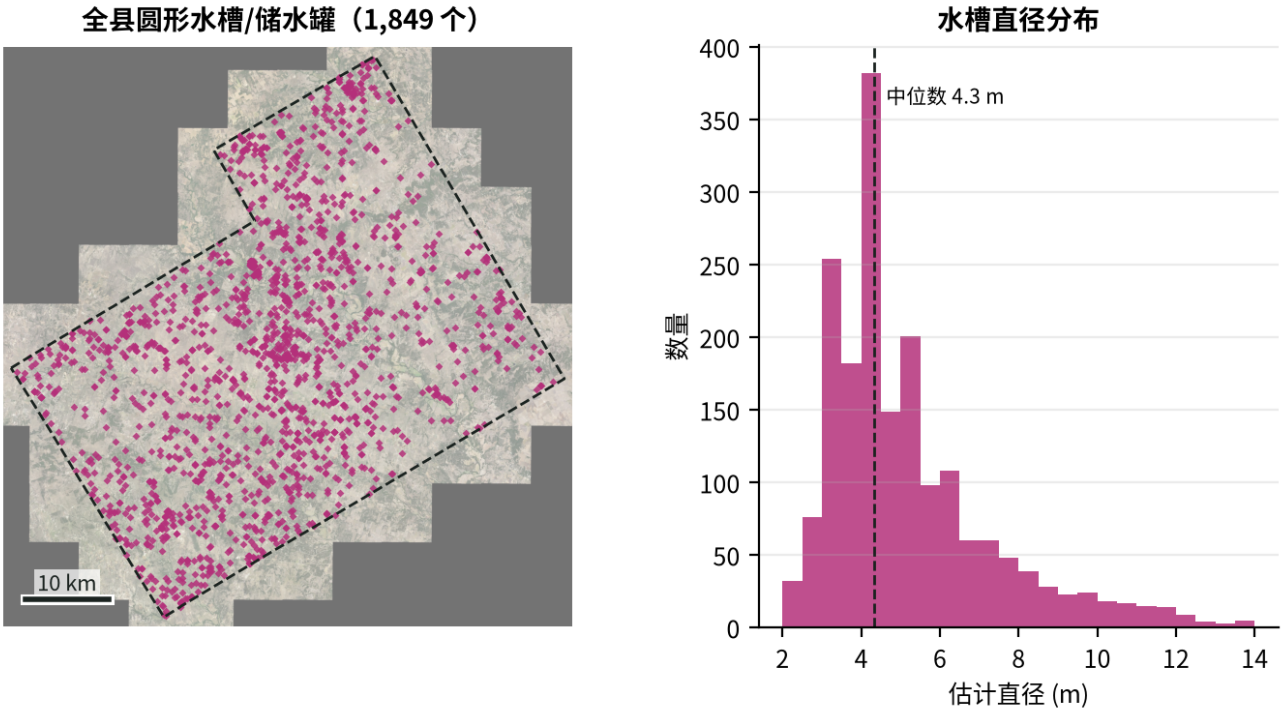


图 11 全县 1,849 个圆形水槽/储水罐的分布与直径。平均约 0.84 个/km²；估计直径中位数 4.3 m，四分位范围 3.8–6.1 m（框尺寸含约 0.4 m 边距）；大于 8 m 的多为水泥蓄水池或大型金属储水罐。



图 12 测试区人工确认的储水设施（z20）。牛道汇聚的圆形水槽、带水的水泥槽、金属和塑料储水罐。



图 13 牧场尺度示例（1.2 km × 1.2 km）。青色为 NAIP 2022 检出的池塘水面，洋红为两阶段模型判定的水槽/储水罐。

7. 自监督学习升级

前面的模型都用 ImageNet 上**有监督**预训练的卷积网络（EfficientNet、ResNet18、YOLO11s）。本章换成近年的做法：先用**不需要标签**的自监督学习得到通用的遥感特征，再用少量标签微调。具体做了三件事：

- **引入公开的卫星自监督基础模型**：DINOv3-sat ViT-L/16（3 亿参数，2025 年发布），在 4.93 亿张 Maxar 卫星图上以 DINOv3 方法自监督训练，从未见过任何人工标签。
- **在本县数据上做领域自适应自监督预训练**（我们自己训练的部分）：从 DINOv3-sat 出发，在完全未标注的本县影像上继续训练。NAIP 分支把输入扩展为 4 波段，让模型**自己学会使用近红外**（DINOv3-sat 只见过 RGB）；Google 分支在 0.25 m 影像上适应牧场设施的细节。
- **换成自监督骨干的下游模型**：池塘分割换成 ViT-L + 多层特征解码器 + 全分辨率细节分支；水槽检测换成基于 ViT 的稠密检测器；水槽类型分类换成 ViT 分类器。

7.1 自监督预训练怎么做

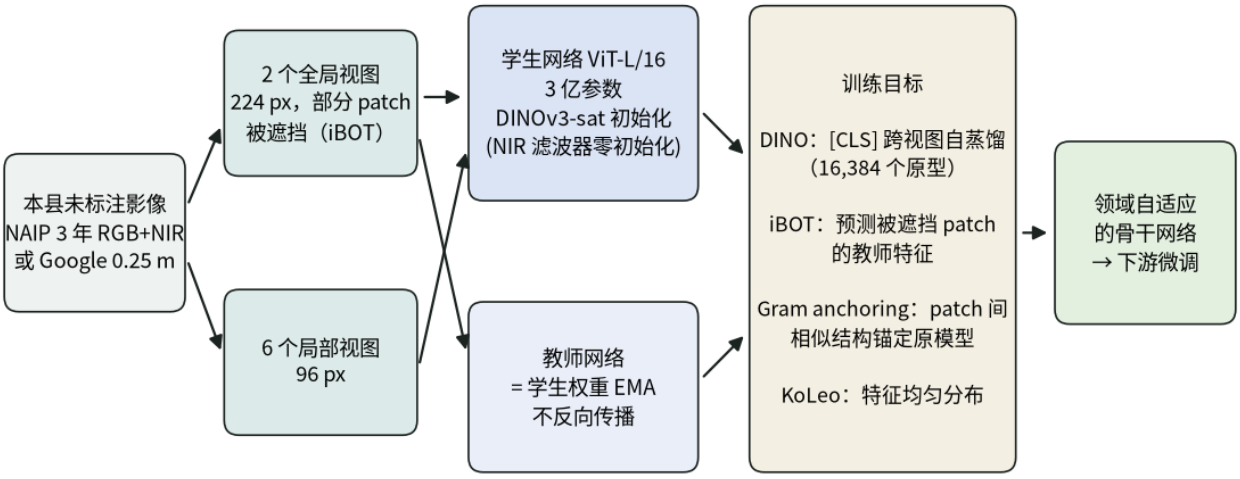


图 14 领域自适应自监督预训练。每张未标注影像生成 2 个全局视图和 6 个局部视图；学生网络学习让各视图的表示与教师网络（学生权重的指数滑动平均）一致，并预测被遮挡 patch 的教师特征。Gram anchoring 让 patch 之间的相似结构不偏离原 DINOv3-sat，防止继续训练时特征退化。

设置	NAIP 分支	Google 分支
未标注数据	NAIP 2018/2020/2022 全县 231 幅（约 100 GB），随机 192 m 窗口	全县 52 万张 z19 瓦片（约 0.25 m），随机 96 m 窗口
输入	RGB + 近红外 4 波段（近红外滤波器零初始化）	RGB
目标函数	DINO（[CLS] 自蒸馏，16,384 原型）+ iBOT（遮挡 patch 预测）+ KoLeo + Gram anchoring；教师为 EMA（0.994→1）	
训练量	6,000 次迭代 × 96 张 × 8 视图 ≈ 58 万张影像*	7,000 次迭代 × 96 张 × 8 视图 ≈ 67 万张影像
硬件 / 用时	2 × A100 80 GB，约 3.5 小时	2 × A100 80 GB，约 4 小时
结果	无坍塌（教师熵 3.4–4.0，特征方差稳定）；权重中位相对变化 1.6%；近红外滤波器从 0 增长到 RGB 的 7%	无坍塌；权重中位相对变化 1.4%

*计划 7,000 次迭代，在约 6,500 次时一个数据加载进程因内存不足被系统终止；使用第 6,000 次的检查点，此时学习率已按余弦计划衰减到接近最小值。

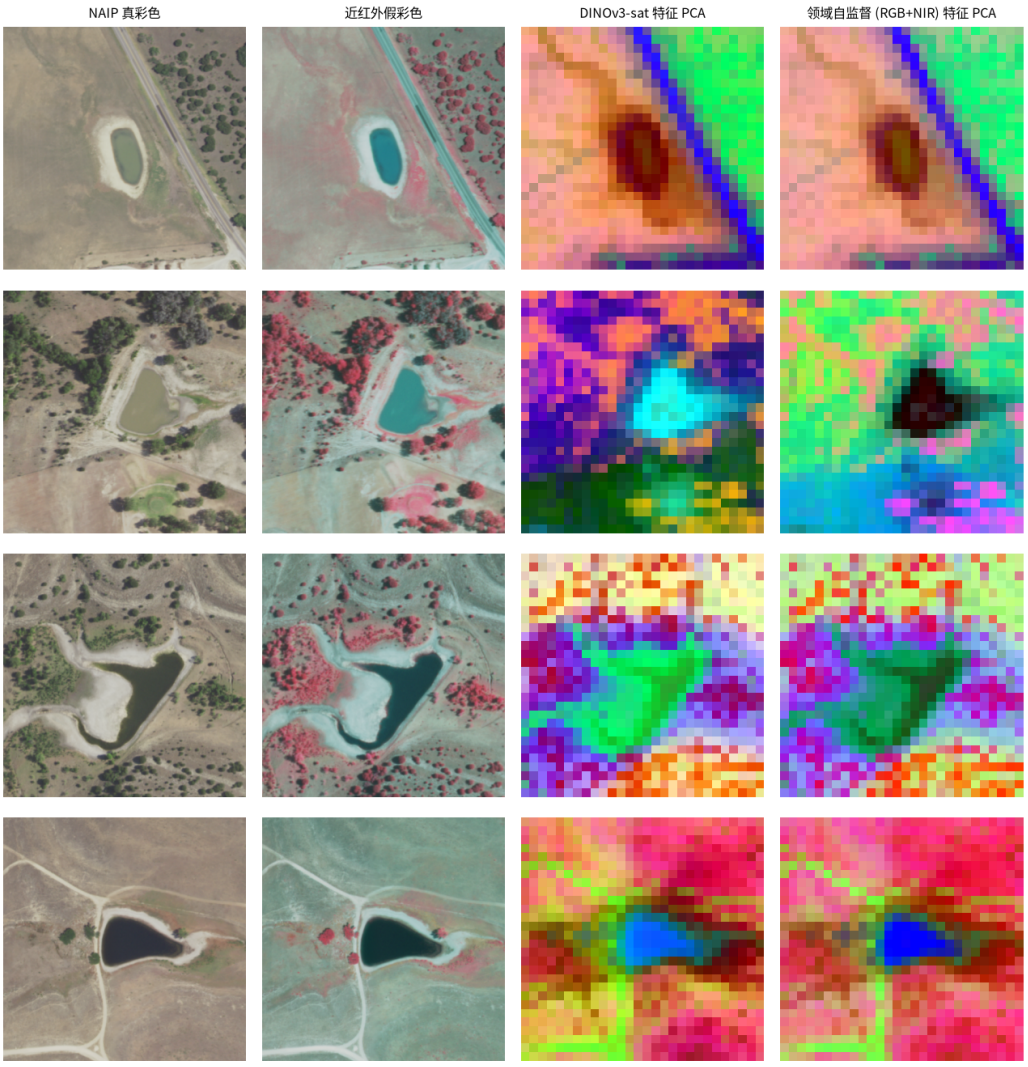


图 15 自监督特征可视化（测试区，无任何标签）。右两列是 patch 特征的前 3 个主成分伪彩色：模型在没见过任何标签的情况下，已经把池塘水面、裸露的库岸、林地、道路分成不同的特征簇。

7.2 池塘分割：结果

所有模型使用同一套弱标签、同样的采样和训练步数，在同一测试区评估。"2×"表示把影像放大 2 倍再送入 ViT：0.6 m 下一个 16 像素 patch 覆盖 9.6 m × 9.6 m，比很多小池塘还大，放大后每个 token 只覆盖 4.8 m。

模型（测试区，NAIP 2022）	预训练	像素 IoU	目标精度	目标召回	F1	NWI 召回
U-Net v2 EfficientNet-B4（原方案）	ImageNet 有监督	0.829	0.915	0.764	0.833	0.81
ViT-L，仅 RGB，1×	DINOv3-sat 自监督	0.805	0.901	0.648	0.754	0.81
ViT-L，RGB+NIR，1×	DINOv3-sat 自监督	0.884	0.978	0.658	0.787	0.74
ViT-L，RGB+NIR，1×	**+ 本县领域自监督**	0.883	0.967	0.697	0.810	0.74
ViT-L，RGB+NIR，2×	DINOv3-sat 自监督	0.898	0.932	0.764	0.840	0.76
ViT-L，RGB+NIR，2×	**+ 本县领域自监督**	0.881	0.901	0.767	0.829	0.79
集成：U-Net v2 + ViT-L 2×（最终）	**两者概率平均**	**0.905**	**0.943**	**0.766**	**0.845**	**0.81**

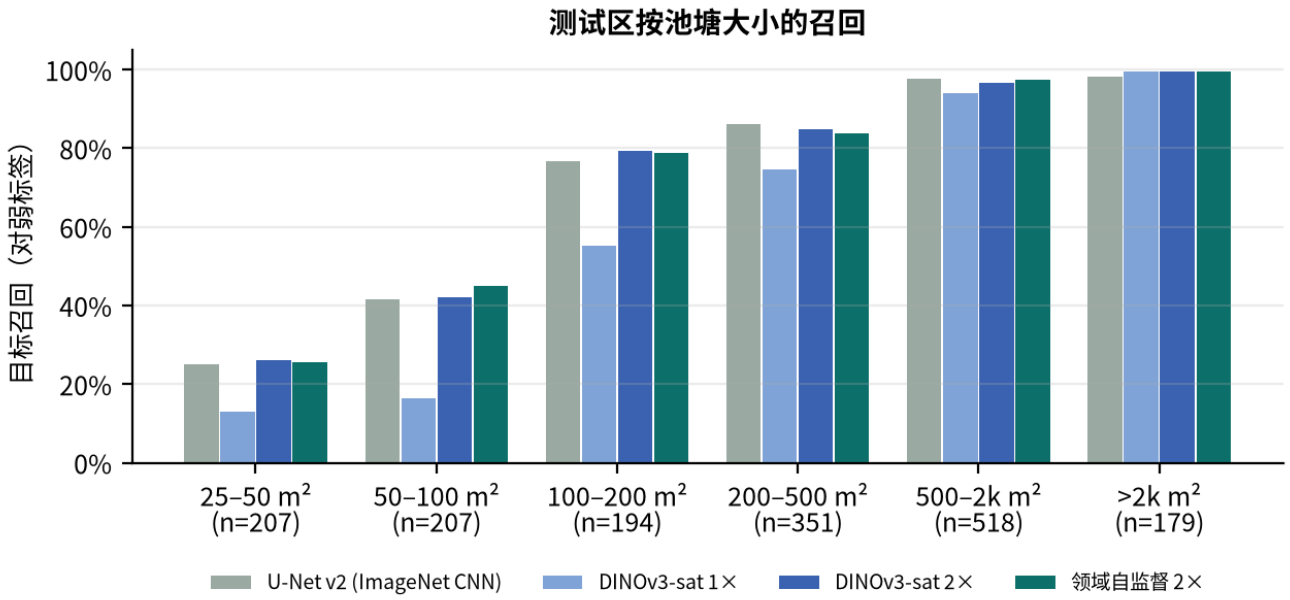


图 16 按池塘大小的召回。ViT 在 1× 时漏掉大量小于 500 m² 的小池塘（一个 patch 就有 92 m²）；放大 2 倍后小池塘召回恢复到与 CNN 相当，同时保留了 ViT 更准的边界（像素 IoU 0.90）和更少的误检。

人工核验 2× ViT 的 60 个随机检出：51 个真实池塘、5 个误检、4 个存疑，精度 85%（严格）–92%（宽松），与 U-Net 的 88–93% 相当。5 个误检中 3 个是住宅后院泳池，已可用"靠近建筑"标记过滤。

结论：

- 自监督 ViT 的提升主要来自三方面：DINOv3-sat 的特征、近红外波段，以及 2× 输入。
- 全量数据下，本县领域自监督在 1× 设置下带来 +0.023 F1（主要是小目标召回 +0.04），在 2× 设置下没有进一步提升。
- 集成 CNN 和 ViT 在所有指标上最好，作为最终池塘模型。
- **标签少时，本县领域自监督的价值最明显**：只用 10% 的训练影像（5 幅）时，领域自监督 ViT 2× 的 F1 为 0.831、IoU 0.897，基本追平用全部数据训练的 U-Net（0.833 / 0.829），也高于同样只用 10% 数据的 U-Net 和 DINOv3-sat（见下表）。

只用 10% 训练影像（5 幅）	像素 IoU	目标精度	目标召回	F1	NWI 召回
U-Net v2（ImageNet 有监督）	0.827	0.910	0.740	0.816	0.81
ViT-L 2×（DINOv3-sat 自监督）	0.883	0.812	0.825	0.819	0.86
ViT-L 2×（+ 本县领域自监督）	**0.897**	**0.892**	**0.778**	**0.831**	**0.81**
参照：U-Net v2 用全部 53 幅	0.829	0.915	0.764	0.833	0.81

池塘的弱标签由规则自动生成，本身数量充足，所以全量数据时三者差距不大；10% 实验模拟的是"只能拿到少量标注影像"的情形（例如换到没有 NWI 的地区）。

7.3 圆形水槽：结果

类型分类器的标注效率。同一组 443 个人工标注、同一 5 折划分，只改变骨干网络和标注量：

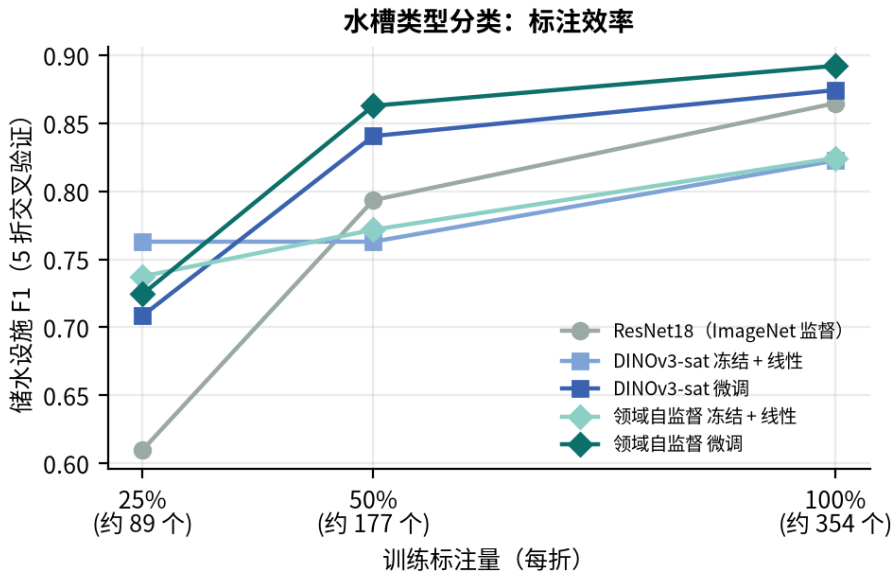


图 17 水槽类型分类的储水设施 F1。只用约 90 个标注时，自监督特征（冻结 + 线性）比 ImageNet ResNet18 高 0.13–0.15；用全部标注时，本县领域自监督（Google 分支）微调最好（0.892 vs ResNet18 0.865）。

稠密检测器替换 YOLO。原两阶段系统的召回上限卡在 YOLO（72%）。新的检测器用 ViT-L 骨干直接输出水槽圆盘概率图，再接 ViT 类型分类器。检测器的训练数据包括 z20 复核过的干净正样本（230 个储水设施）、333 个外观相似的困难负样本（草捆、喂料架、棚子、灌木），以及由稠密检测器在训练区跑出、再经人工标注的第二轮主动学习样本。

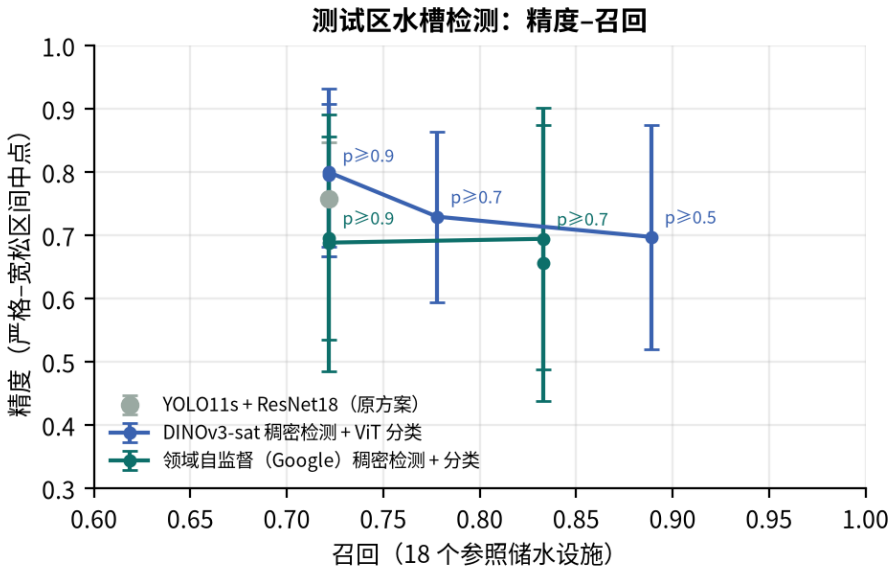


图 18 测试区水槽检测的精度–召回。误差线为严格–宽松精度区间。自监督系统可以在同等召回（72%）下保持相当或更高的精度、找出更多设施，也可以把召回提高到 89%。

测试区水槽系统	召回（18 个参照）	精度（严格–宽松）	测试区检出数	估计真实设施数
YOLO11s + ResNet18（原方案）	72%	67–85%	741	约 490–630
DINOv3-sat 稠密检测 + ViT 分类，p ⩾ 0.8	72%	67–93%	939	约 630–880
DINOv3-sat 稠密检测 + ViT 分类，p ⩾ 0.7（最终）	**78%**	**60–87%**	**1,096**	**约 650–950**
DINOv3-sat 稠密检测 + ViT 分类，p ⩾ 0.5	89%	52–88%	1,337	约 700–1,170
本县领域自监督（Google）稠密检测 + 领域自监督分类，p ⩾ 0.7	83%	49–90%	1,034	约 500–930

精度来自从各系统检出中随机抽取的 48 个样本在 z20 下的人工核验，阈值越高样本越少（22–48 个），精度的不确定性约 ±12–15 个百分点；参照集只有 18 个，召回每差一个就是 5.6 个百分点。

结论：换成自监督 ViT 稠密检测器后，同等召回下找到的真实设施多约 30%，或者召回可从 72% 提高到 78–89%。在 Google 瓦片上做领域自监督，对水槽**分类**有小幅提升，对**检测**没有可测量的提升。

7.4 最终采用的模型

任务	最终模型	相对原方案
池塘水面分割	集成：U-Net v2 (EfficientNet-B4) + DINOv3-sat ViT-L/16 2×（RGB+NIR，自监督预训练）	F1 0.833 → 0.845；IoU 0.829 → 0.905；精度 0.915 → 0.943；召回不变
水槽检测	DINOv3-sat ViT-L/16 稠密检测器（第二轮主动学习数据）	召回 72% → 78–89%
水槽类型分类	DINOv3-sat ViT-L/16 微调（584 个 z20 标注）	同等召回下真实设施数约 +30%
自监督骨干（可复用）	本县领域自监督 ViT-L：NAIP 4 波段版、Google 0.25 m 版	水槽分类全量标注 F1 0.865 → 0.892；池塘 1× F1 +0.023

7.5 用新模型重新生成的全县结果

第 6 节的地图与统计基于原模型；下面是用最终自监督模型（池塘：集成模型，三期 NAIP；水槽：ViT 稠密检测 + ViT 分类，p ⩾ 0.7）重新跑全县的结果。为节省计算，ViT 只在 U-Net 概率 > 0.05 或存在近红外水体像素的 512 像素窗口上运行；其余窗口集成模型本来也不可能检出水体。

全县（县界内）	原模型	自监督模型
池塘足迹	7,915	7,707
有水池塘数 2018 → 2020 → 2022	6,688 → 4,893 → 3,152	6,735 → 4,829 → 3,072
池塘开放水面 2018 → 2020 → 2022（km²）	10.6 → 7.9 → 4.6	12.0 → 8.3 → 4.6
"间歇" / "新蓄水" 类别	799 / 625	647 / 523
圆形水槽 / 储水罐	1,849	3,026

池塘数量与有水趋势和原模型一致；新模型在 2018 年多检出约 1.4 km² 水面（边界更完整），"间歇"和"新蓄水"这类在年份间来回翻转的池塘少了约 20%，说明误检和漏检造成的假变化更少。水槽数量增加约 64%，与测试区"同等召回下检出数多约 48%、真实设施数多约 30%"的结果一致。

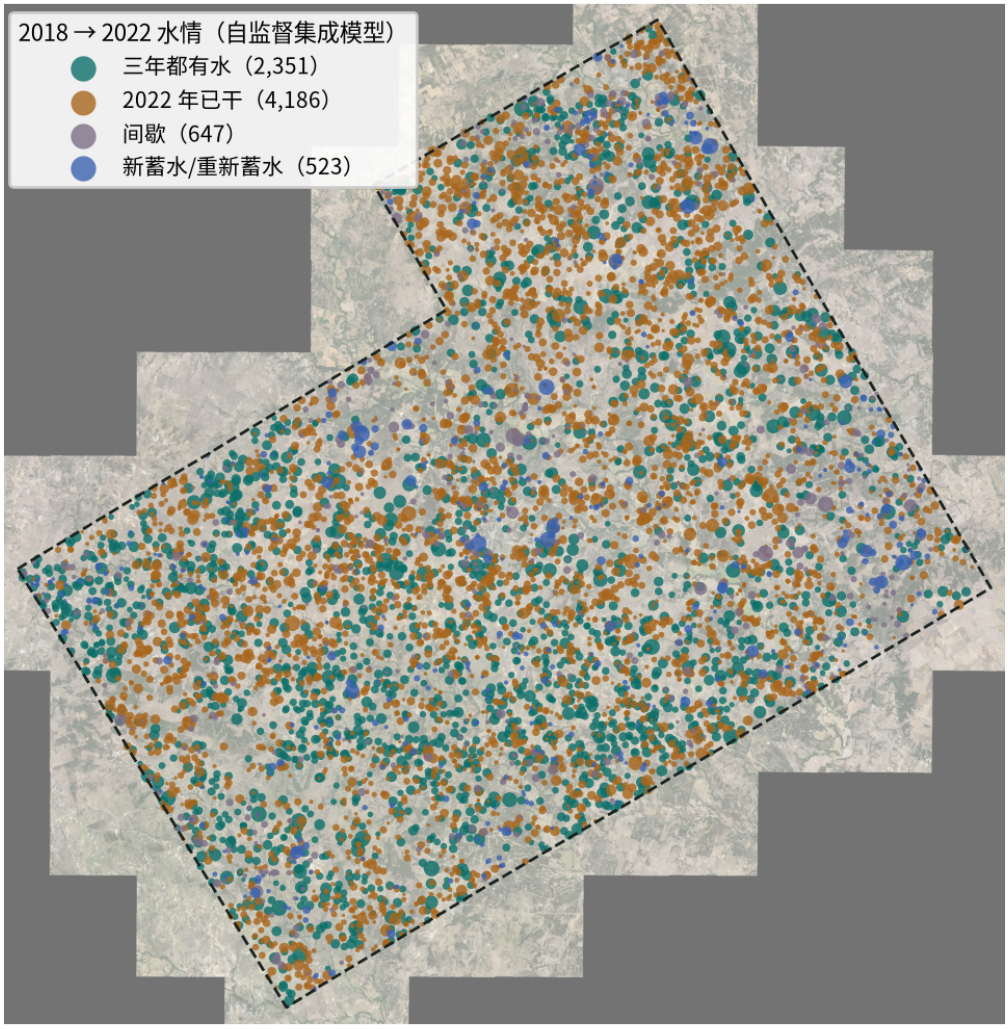


图 19 全县池塘足迹及 2018→2022 水情（自监督集成模型）。

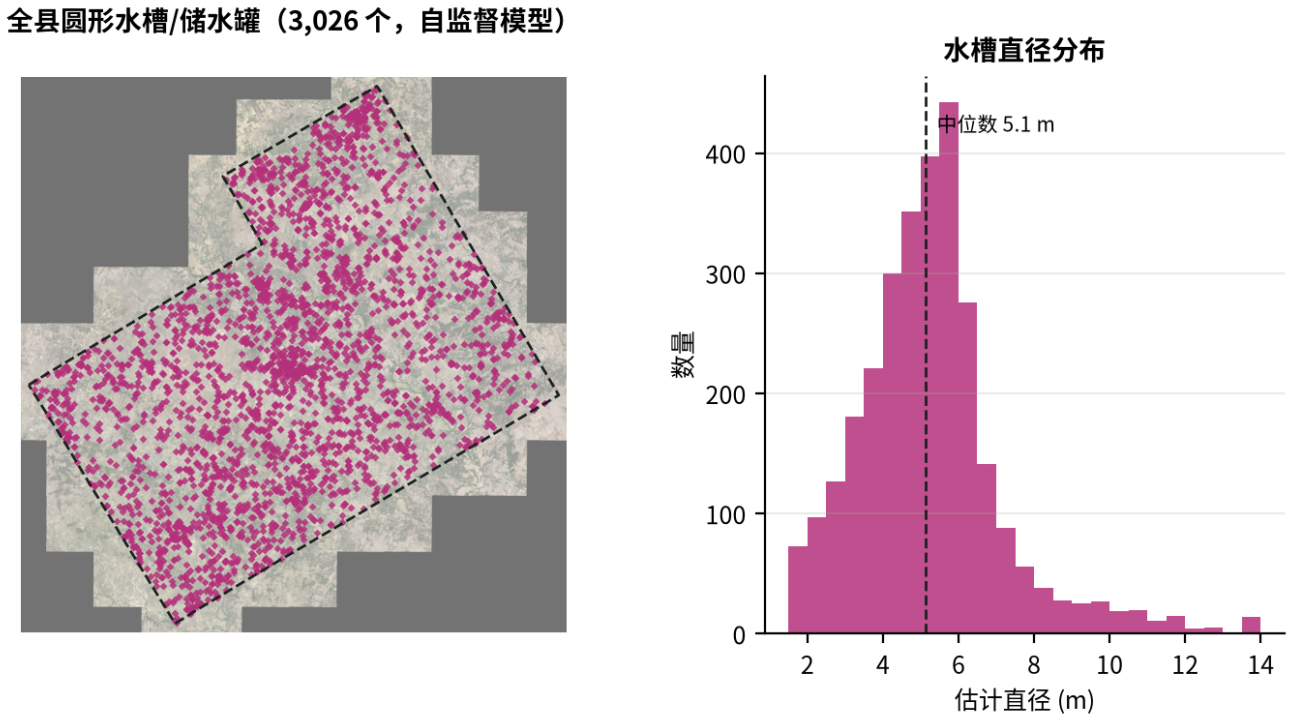


图 20 全县 3,026 个圆形水槽/储水罐（自监督模型）及直径分布。直径由检测出的圆盘面积换算，中位数 5.1 m。

8. 局限与下一步

- **评估样本量。**池塘核验各 60 个、水槽召回参照 18 个、精度样本 33 个，指标的不确定性约 ±10–12 个百分点；正式结论需要更大的核验集，最好有牧场主的实地确认。
- **Google 底图。**拍摄日期不统一也不公开，只适合定位水槽，不能判断某天是否有水；其使用条款限制批量下载。正式项目建议改用授权或公开的高分正射影像（如 TxGIO StratMap，需确认本县覆盖与年份）或无人机。
- **漏检模式。**池塘：绿藻/水草覆盖、树荫下的小水面——标注约 200 个本地池塘即可改善。水槽：树荫遮挡、棚院内——补充 100–200 个 z20 样本（含车辆、拖车、棚子负样本）。
- **监测频率。**NAIP 每两年一次，不足以做季节性跟踪。大池塘可迁移到 Sentinel-2（10 m，5 天）或 PlanetScope（3 m，每天）；水槽是否有水需要 ⩽ 0.3 m 的定期影像或地面水位传感器。
- **按牧场输出。**拿到牧场主提供的 ranch 边界后，即可直接输出每个牧场的池塘和水槽清单及逐年水情。

附录：输出文件

文件（相对 /home/ychen289/whe/pond ）	内容
outputs/vector/water_sources_2022_hamilton.geojson	2022 年县界内全部水体检出（4,974 个），含面积、圆度、类别、误检标记
outputs/vector/water_sources_{2018,2020,2022}.gpkg	三期全部水体检出
outputs/pond_inventory_multiyear_hamilton.csv	7,915 个池塘足迹的逐年水面面积与有水/干涸状态
outputs/vector/round_tanks_hamilton_final.geojson	全县 1,849 个圆形水槽/储水罐（检测置信度、储水概率、估计直径）
outputs/vector/round_tanks_county_v3_typed.gpkg	全部水槽候选及四类概率
outputs/prob/{year}/*.tif	逐像素水体概率图
outputs/vector/water_sources_ssl_{2018,2020,2022}.gpkg 、 outputs/pond_inventory_multiyear_ssl.csv	自监督集成模型的三期水体检出与逐池塘水情（推荐使用）
outputs/vector/round_tanks_hamilton_ssl.geojson	自监督模型的全县 3,026 个水槽/储水罐（推荐使用），含检测置信度与四类概率
runs/ssl/naip/ckpt.pt 、 runs/ssl/google/ckpt.pt	本县领域自监督 ViT-L 骨干（NAIP 4 波段 / Google RGB）
runs/seg_dinov3sat_rgbn_x2/ 、 runs/tankdet_dinov3sat_v2/ 、 runs/tank_type_vit_dinov3.pt	最终 ViT 池塘分割、稠密水槽检测、水槽类型分类权重
outputs/eval/ssl/	自监督对比实验的全部评估与人工核验记录
outputs/eval/ 、 data/manual/	全部评估结果、人工标注与核验记录
README.md 、 scripts/	完整复现流程（01–29 号脚本及 ssl_*.py）